Nghiên cứu và Ứng dụng Kiến trúc Multi-Agent kết hợp Advanced RAG trong Trích xuất Dữ liệu Phi cấu trúc nội bộ bảo mật

Tên dự án: VTAgent

1. Khảo sát

1.1 Khảo sát đối tượng người dùng & điểm nghẽn nghiệp vụ

- Người dùng: Cá nhân, nội bộ tổ chức cần lưu trữ, trích xuất, tóm tắt, so sánh, tổng hợp các văn bản bảo mật không thể lộ như hợp đồng, thông tin khách hàng.

- Điểm nghẽn thủ công lớn nhất hiện nay:

+ Nếu rà soát, tổng hợp thủ công các loại giấy tờ, tài liệu có thể đến hàng giờ

+ Nếu dùng các dịch vụ AI trên internet => vấn đề bảo mật

+ Nếu đưa giải pháp AI hỗ trợ vào đây => Giảm chi phí nhân lực

1.2 Giới hạn miền tài liệu

- Nếu dự án chạy trên máy tính cá nhân có năng lực tính toán hạn chế, ta cần giới hạn.

- Các tài liệu tải lên không quá 20 trang, và số tài liệu tải lên không quá 3 - 5.

- Các tài liệu có thể đẩy vào hệ thống qua GG drive hoặc đẩy lên trực tiếp

- Định dạng cho phép: PDF, Docx, xlsx, csv, image, pptx,..

1.3 Tính năng (In-Scope vs. Out-of-Scope)

Tính năng	In-Scope	Out-of-Scope
Khả năng nạp tài liệu	- Cho phép người dùng nhập tài liệu từ ggDrive tải lên trực tiếp - Hỗ trợ đa dạng các định dạng	- Tự động nạp dữ liệu từ Internet, hay nguồn khác
Tính toán	Tính toán chính xác từ các số liệu tài lên (tool caculate cho Agent)	Tự động đồng bộ hóa hóa đơn sang phần mềm khác

Tính năng	In-Scope	Out-of-Scope
Rà soát rủi ro	Bắt các lỗi cơ bản: Tỷ lệ phạt vượt trần luật định (ví dụ >8% theo Luật Thương mại), thiếu điều khoản bảo mật.	Khẳng định hợp đồng có giá trị pháp lý tuyệt đối hay thay thế luật sư tranh tụng.
Hạ tầng	Chạy trên 1 máy local (Docker, Ollama, LangGraph, Web UI đơn giản).	Triển khai phân tán nhiều node (Kubernetes)

1.4 Yêu cầu nghiệm thu

Hệ thống được nghiệm thu nếu thỏa mãn:

- Các chỉ số Benchmark/eval đạt yêu cầu
- Một giao diện người dùng đơn giản, thân thiện (Web UI): Cho phép kéo thả file tài liệu vào.
- Khả năng xuất báo cáo: Nút bấm xuất toàn bộ kết quả thẩm định ra file Markdown hoặc JSON chuẩn.
- Có Working memory Short/Long – tern.
- Các câu trả lời từ hệ thống có trích dẫn đầy đủ để người dùng manual check.
- Tốc độ inference nhanh, đáp ứng khả năng real-time (sẽ theo BRD).

1.5 Phương án Back – up

- Em cần 1 buổi trao đổi với thầy về đề tài em đề xuất về độ phức tạp, tính khả thi, và phạm vi có thể thực hiện, nếu quá phạm vi => thu nhỏ dự án lại phục vụ cho 1 nhóm người dùng như tra cứu văn bản pháp luật (cho phép nạp vào hơn 100 tài liệu, mà vẫn tra cứu chính xác, điều này notebook LM chưa làm được).